

Trabalho Final - SVM

Reconhecimento de Padrões - UFMG

Guilherme Capanema de Barros (7 de Novembro de 2017)

1 Introdução

SVMs (*Support Vector Machines*) são modelos de aprendizado supervisionado que permitem solucionar tanto problemas de classificação como de regressão.

Em geral, as SVMs possuem dois parâmetros de ajuste:

C é o parâmetro de custo. Quanto maior for o valor de C , mais custoso é considerado um erro de classificação, de forma a tender ao *overfitting*.

γ é o parâmetro do *kernel*. Para funções de *kernel* gaussianas, está relacionado ao raio da base de cada uma. Dessa forma, a diminuição de γ tende ao *overfitting*.

2 Escolha dos parâmetros

2.1 *Grid Search*

Uma das formas mais comuns de seleção automática dos parâmetros das SVMs é uma busca exaustiva por diversas combinações de C e γ .

O método, chamado *grid search*, gera valores para os parâmetros em intervalos definidos. Para cada combinação, o desempenho do modelo é avaliado, por exemplo, usando validação cruzada.

Com um espaçamento suficientemente pequeno entre os valores, o *grid search* é capaz de encontrar parâmetros muito próximos dos ótimos. No entanto, o custo computacional é muito alto.

2.2 *Simulated Annealing*

Para reduzir o número de parâmetros avaliados e, assim, reduzir o custo computacional da seleção de parâmetros, podem ser aplicados métodos de otimização.

Como, em geral, a função de custo é fortemente multimodal, métodos baseados em gradiente descendente tendem a mínimos locais. Assim, a aplicação de metaheurísticas (MHs) se torna interessante.

Uma possibilidade é aplicar a MH *Simulated Annealing* (SA), baseada no recozimento de metais. A SA aceita movimentos de piora com uma probabilidade que decresce com o número de iterações, de forma a explorar bem o espaço de busca e, ao final, convergir para uma bacia de atração. Embora não haja garantia de otimalidade global, a SA tende a encontrar resultados bem próximos.

Referências

- [1] BOARDMAN, Matthew and Thomas TRAPPENBERG, 2006. A Heuristic for Free Parameter Optimization with Support Vector Machines, Proceedings of the 2006 IEEE International Joint Conference on Neural Networks (IJCNN 2006), pp. 1337-1344.
- [2] MBAULT, F. and K. LEBART, 2004. A stochastic optimization approach for parameter tuning of support vector machines, Proceedings of the 17th International Conference on Pattern Recognition (ICPR 2004), Volume 4, Pages 597-600.